Índice

1. Introdução
2. Contextualização do Dataset
3. Importação dos Dados
4. Limpeza dos Dados
5. Identificação de Duplicados na Base de Dados
6. Estimação do Erro nas Estatísticas
7. Estrutura do Banco de Dados
8. Modelo Relacional e Queries Solicitadas
9. Bibliografia

1. Introdução

No âmbito da unidade curricular de Gestão de Big Data propôs-se a realização de um projeto com recurso à ferramenta de MySQL aplicável a um dataset.

Relativamente ao dataset apresentado, este denominado de "ATP Tennis Professionals" refere-se a todos os jogos individuais de 10 361 jogadores (do sexo masculino) que estão no top 500 de jogadores durante o período de 28/03/1973 e 14/02/2022.

Inicialmente para a realização do projeto foi necessário compreender a base de dados disponibilizada, bem como perceber o contexto de cada variável e respetivo conceito.

Após compreender a base de dados e as suas principais limitações, foi necessário proceder à verificação dos dados e limpeza dos mesmos, de forma a uniformizar os dados que, posteriormente, seriam utilizados para a criação do modelo relacional. Para além de se uniformizar os dados, também um passo importante foi tornar os dados conformes com as informações e regras dos torneios de ténis.

Dada a padronização dos dados, foi possível compreender as relações entre as várias tabelas e atributos, de forma a criar o modelo relacional subjacente a estas relações e que permitam responder às queries pretendidas.

Para além dos dados disponibilizados, ainda recorremos à junção de dados referentes aos países e respetivas siglas, bem como à divisão destes países em continentes.

2. Contextualização do Dataset

Como já referido, o dataset refere-se a torneios de ténis da ATP (Association of Tennis Professionals). Este conjunto de dados reúne informações sobre diferentes torneios decorridos entre 1973 e 2022, permitindo, assim, uma análise abrangente sobre esses torneios, tendo em conta jogadores, rankings, condições jogadas e outras características destes.

De acordo com o dataset apresentado verifica-se que existem 14 variáveis, nomeadamente:

- ***PlayerName*:** refere-se aos nomes dos jogadores participantes
- ***Born*:** apresenta a cidade e país onde os jogadores nasceram
- ***Height*:** inclui a altura dos jogadores em centímetros (*cm*)
- ***Hand*:** refere a(s) mão(s) dominante(s) do jogador e a forma como realiza o *backhand* na raquete
- ***Tournament*:** apresenta o nome do torneio realizado
- ***Location*:** inclui a cidade e país do torneio realizado
- ***Date*:** apresenta a data do torneio, incluindo a data de início e a data de fecho
- ***Ground*:** designa o tipo de superficie do campo
- ***Prize*:** refere-se ao prémio recebido pelos jogadores
- ***WL*:** mostra se o jogador venceu ou perdeu um determinado jogo
- ***Score*:** apresenta o resultado do jogo
- ***Round*:** refere-se à fase de competição em que se encontra o torneio
- ***OpponentRank*:** representa a posição no ranking ATP do adversário que o jogador enfrentou
- ***Opponent*:** nome do adversário que o jogador enfrentou num determinado jogo

Atendendo aos dados analisados, foi possível verificar a existência de inconsistências que necessitam de serem uniformizadas, de forma a permitir que os dados estejam corretos na Base de Dados e que traduzam valor para as estatísticas que sejam pretendidas.

3. Importação dos Dados

De forma a podermos importar os dados para o MySQL temos de transferir o ficheiro zipado "atpplayers.csv" e colocar em "C:\xampp\mysql\bin" o ficheiro.

Antes de abrir o cmd é necessário criar uma nova tabela no MySQL designada de "atp", após isto temos de ir ao comando SQL e meter o seguinte comando disponibilizado pelo professor:

```
Create database atp_alunos;
CREATE TABLE `atpplayers` (
  `PlayerName` varchar(100) DEFAULT NULL,
  `Born` varchar(100) DEFAULT NULL,
  `Height` varchar(100) DEFAULT NULL,
  `Hand` varchar(100) DEFAULT NULL,
  `Tournament` varchar(100) DEFAULT NULL,
  `Location` varchar(100) DEFAULT NULL,
  `Date` varchar(100) DEFAULT NULL,
  `Ground` varchar(100) DEFAULT NULL,
  `Prize` varchar(100) DEFAULT NULL,
  `WL` varchar(100) DEFAULT NULL,
  `Score` varchar(100) DEFAULT NULL,
  `Round` varchar(100) DEFAULT NULL,
  `OpponentRank` varchar(100) DEFAULT NULL,
  `Opponent` varchar(100) DEFAULT NULL
) ENGINE=InnoDB DEFAULT CHARSET=utf8;
```

De seguindo, quando já tivermos a tabela com as colunas criadas, vamos para o cmd e corremos o código "mysqlimport --ignore-lines=1 --fields-terminated-by=, --fields-enclosed-by=\" --verbose --local -u root atp_alunos atpplayers.csv".

Desta forma, temos a tabela criada e os respetivos dados nas colunas que lhes correspondem.

4. Limpeza dos Dados

Inicialmente, será apresentado uma breve explicação das alterações que ocorreram na base de dados e de algumas sugestões necessárias a considerar para alguns passos adicionais em algumas colunas.

De destacar que através do comando SELECT verificou-se que apenas a coluna "*PlayerName"* não necessita de nenhuma alteração.

4.1. Coluna "*Born"*

Tendo em conta, os vários formatos como os dados eram apresentados nesta coluna, nomeadamente, "Cidade, País", "Cidade, Estado, País", apenas "Cidade" ou apenas "País", decidiu-se uniformizar os mesmos. Para tal e tendo como objetivo facilitar as análises estatísticas e manter a base de dados consistente, decidiu-se separar a coluna em duas novas colunas, designadamente, "*Born_City"* (destinada à cidade onde nasceu o jogador) e "*Born_Country"* (referente ao país onde nasceu o jogador). A par da criação destas duas novas colunas, remove-se a coluna "*Born"* para eliminar dados que não acrescentam valor à estatística e trazem redundância aos dados.

Atendendo aos diferentes formatos de registo dos dados houve a necessidade de proceder na limpeza de forma distinta:

- **Registo que inclui três partes (Cidade, Estado, País)**
  Normalmente, estes casos ocorrem em países que estão divididos por estados ou regiões, pelo que de forma a facilitar as queries posteriores apenas eliminou-se "Cidade", tendo-se separado da seguinte forma:
  - Born_City recebe a "Estado"
  - Born_Country recebe o "País"
- **Registo que inclui duas partes (Cidade, País)**
  Quando a coluna "*Born"* apresenta duas partes, nomeadamente, a cidade e o país, pelo que distribui-se da seguinte forma:
  - Born_City recebe a "Cidade"
  - Born_Country recebe o "País"

- **Registo que inclui apenas a Cidade**

  Quando a coluna "*Born"* apresenta apenas a cidade, nomeia-se da seguinte forma nas duas colunas:

  - Born_City recebe a "Cidade"
  - Born_Country transforma-se em NULL

- **Registo que inclui valores vazios ou nulos**

  Para registos onde a coluna "*Born"* está sem dados ou NULL, colocamos NULL em ambas as colunas ("*Born_City" e "Born_Country"*).

Apesar das alterações realizadas, ainda existem problemas que necessitam de ser resolvidos, nomeadamente, valores que estão mal distribuídos nas colunas e valores em falta.

Quando se trata de valores mal distribuídos nas colunas é necessário mover estes da coluna "*Born_City"* para a coluna "*Born_Country"*.

Relativamente aos valores em falta na coluna "*Born_Country"*, analisa-se se existem registos na tabela que associam a cidade, já previamente preenchida, com um país associado. Se sim, usa-se esse país para preencher automaticamente. Caso contrário, teremos que, através da pesquisa num browser, procurar o país que está associado à cidade apresentada.

Nota: quando temos vários registos do mesmo jogador e existem valores em falta em "*Born_City" e "Born_Country"*, deve-se analisar se esses jogadores têm essa informação já preenchida e uniformizar todos os registos.

Depois da limpeza geral dos dados, ainda se verificam casos específicos que necessitam de correção manual. Estes são erros que são excecionais e que necessitam de ser tratados individualmente.

No caso de termos valores iguais em ambas as colunas tem de se verificar em qual coluna deve estar associada, por exemplo, no caso de "New York" deve-se meter em "*Born_City"* e procurar o país correspondente.

Nota: Como os Estados Unidos têm um sistema de abreviações de duas letras para cada estado, normalizámos todos os nomes completos de Estados para as suas abreviações oficiais.

4.2. Coluna "*Height*"

Na coluna "*Height"* verificou-se inconsistências nestes registos. Por exemplo, verificou valores irreais como 244 cm e 3 cm, não podendo estes serem contabilizados para as estatísticas.

Desta forma, teve de se definir um intervalo de altura tido em conta na coluna "*Height_cm_clean"* (coluna esta criada para a limpeza dos dados) com valores entre 147 cm a 211 cm. Todos os valores que não integravam este intervalo eram registados como NULL.

A percentagem de linhas que foram alteradas pelo comando UPDATE foi de aproximadamente 74%.

4.3. Coluna "*Hand*"

O processo consistiu na transformação e limpeza de dados que se focou em desagregar a informação da coluna original "*Hand"* em duas novas colunas. O objetivo desta intervenção foi clarificar a análise dos dados e melhorar a qualidade das estatísticas.

1. **Coluna Original ("*Hand*"):** contém registos mistos, agregando a mão dominante do jogador e o estilo do seu *backhand* (por exemplo: "Right-Handed, Two-Handed Backhand")
2. **Novas Colunas Criadas:**
    - ***"Hand_Dominante"*:** esta nova coluna passou a registar apenas a mão com que o atleta joga (por exemplo: Right-Handed, Left-Handed, Ambidextrous)
    - **"*Backhand_Style*":** esta coluna contém o estilo de *backhand* utilizado (por exemplo, Two-Handed Backhand, One-Handed Backhand, Unknown Backhand)

Esta separação é crucial, pois permite agora a análise isolada de cada característica, ou seja, analisar a mão dominante dos tenistas independentemente do tipo de *backhand* e vice-versa.

Analisando estatisticamente, a maioria dos registos apresentam-se "Right-Handed, Two-Handed Backhand" com aproximadamente 37%. Contrariamente, a categoria "Ambidextrous, Two-Handed Backhand" é considerada uma categoria residual apresentando apenas, aproximadamente, 0,1% dos registos.

Relativamente aos registos que não existem informações sobre o estilo de *backhand*, tendo em conta qualquer uma das mãos dominantes (ou ambas), estes representam 32% dos dados,

dificultando as estatísticas que possam ser realizadas sobre este estilo, e consequentemente comprometendo a fiabilidade das análises necessárias.

Dos dados que estavam inicialmente como NULL, estes representavam cerca de 15% do *dataset*, valor que ainda é significativo e pode ter impacto nas estatísticas.

4.4. Coluna "*Tournament"*

Na análise da coluna "*Tournament"* verificou-se a necessidade de proceder a diversas alterações que comprometiam a integridade e uniformização dos dados, bem como das estatísticas posteriores. O objetivo principal era garantir que o nome de cada torneio era apresentado de forma consistente e única no *dataset*, independentemente das variações históricas, de escrita ou de formato de cada torneio.

Inicialmente, procedeu-se à limpeza dos espaços vazios no início e fim de cada registo através do comando TRIM, de forma a facilitar os comandos UPDATE posteriores. Ainda foi necessário uniformizar o "vs", de modo a garantir que existissem espaços consistentes antes e depois deste marcador, pois havia diversos valores distintos, nomeadamente, "vs", "v", "v.", "vs.".

De seguida, verificou-se a importância de padronizar os nomes dos eventos e para tal exportou-se o ficheiro somente da coluna "*tournament_clean*" onde estes foram mapeados e, só depois, iniciou-se a sua atualização.

Destaca-se assim algumas variações nos nomes dos torneios que necessitaram de uma análise profunda para garantir que vários nomes de torneios que foram alterando-se ao longo do tempo, estavam associados a um único nome padronizado.

- ***Grand Slam* da Austrália**
  - Apresentava-se antigamente como "*Australian Championships*";
  - Ainda incluíam sufixos "-1" e "-2" que indicavam que o mesmo torneio realizava-se em semanas distintas (apesar de ser raro, mas que se verificou no ano de 2021, por exemplo), bem como quando o evento principal estava associado a dados duplicados que estavam presentes;
- ***Roland Garros* ou *Grand Slam* de Paris**
  - Antes apresentado como "*French Championships*", nome histórico e oficial;
  - Atualmente este é associado mais comumente a "*Roland Garros*" ou "*Grand Slam* de Paris";

- Por fim, encontrou-se o caso de termos o "Preliminary Round" que está igualmente associado a este torneio;

- **ATP Finals**
  - Através da análise e pesquisa sobre o torneio de encerramento da temporada da ATP, verificou-se que os seguintes valores referem-se ao mesmo torneio, nomeadamente:
    - "*Nitto ATP Finals"*, "*ATP Finals*", "*Tennis Masters Cup*" e "*ATP Tour World Championship*"
  - Embora, os nomes dos torneios tenham mudado ao longo do tempo devido a patrocinadores ou alterações históricas, todos representam **este evento que reúne os melhores jogadores da temporada**. Assim, padronizar estes valores para "*ATP Finals*" garante a consistência dos dados e facilita as consultas e análises posteriores;
- **US Open**
  - Surgiram alguns casos em que vários torneios como "*US open*", "US championships" que se referem ao torneio atualmente designado "*US Open*";
  - Para tal, teve de se uniformizar estes valores de forma a termos um valor único neste campo;
- **Next Gen ATP Finals**
  - Através da análise e pesquisa relativamente a estes valores confirmou-se que "*Next Gen ATP Finals*" e "*Intesa Sanpaolo Next Gen ATP Finals*" referem-se ao mesmo torneio;
  - Este torneio é relativo ao torneio de Final de Época destinado aos jogadores Sub-21, pelo que se padronizou nos dados o nome "*Next Gen ATP Finals*";
  - Deste modo, apesar de encontrarmos especificidades entre estes dois nomes, o que os diferencia é que o "*Next Gen ATP Finals*" é o nome oficial e genérico do torneio e o "*Intesa Sanpaolo Next Gen ATP Finals*" é o nome oficial do torneio com a inclusão do seu patrocinador, neste caso, Intesa Sanpaolo;
- **Masters 1000**

  Neste caso, também se verificaram vários torneios ATP Masters 1000 que não estavam padronizados e assim removeu-se sufixos e nomes antigos, nomeadamente:
  - **Rome Masters 1000** (incluía "*Rome*", "*Rome-1*", "*Rome-2*", "*Rome-3*", "*ATP masters 1000 rome*");
  - **Miami Masters 1000** (antes das alterações tinha-se "*Miami*", "*Key biscayne*", "*ATP Masters 1000 miami*");

- **Monte Carlo Masters 1000** (anteriormente havia registos de "*Monte Carlo*", "*ATP masters 1000 monte carlo*");
- **Indian Wells Masters 1000** (apresentava torneios como diversas designações como, "*indian wells*", "*atp masters 1000 indian wells*");
- **Hamburg (ex-Masters 1000)** (este torneio foi despromovido de Masters 1000, pelo que é um evento histórico e anteriormente era apresentado como "*Hamburg*", "*atp masters 1000 hamburg*").

Nota: Destaca-se que encontrou-se em vários torneios o sufixo "*WTC*" que está associado a um torneio histórico pelo que se alterou o mesmo, de forma a padronizar os torneios e de acordo com os nomes atuais.

Tivemos ainda de limpar alguns erros de formatação "&c" que se refere ao código HTML para "&".

Assim, analisando a nossa coluna, podemos comprovar que não existem valores NULL, nem strings vazias, pelo que todos os registos têm um valor associado, apesar de não ser possível garantir que todos estão padronizados.

Por fim, o processo ainda incidiu na padronizou de outros eventos, tendo em conta a remoção de sufixos (como -1, -2, 1, 2, 3), de modo a padronizar o nome principal do torneio, pois estes sufixos referem que as semanas em que o evento se realizou foram diferentes. Ainda incluiu-se UPDATE para outros casos específicos, como por exemplo, "*Stockholm Open"*, "*Vienna Open"*, "*Acapulto Open"*, "*Davis Cup Finals"* e "*ATP Masters 1000 Paris"*.

Após este passo de verificação da coluna "*Tournament*" houve a necessidade de analisar conjuntamente as colunas "*Tournament*" e "*Location*" de forma a verificar se o nome do torneio correspondia ao local onde este se realizava.

Esta validação revelou-se desafiante devido à falta de informação, tanto do site da ATP como da ITF. Em muitos casos, ao procurar informações sobre o torneio, na coluna "*Tournament*" havia espaços vazios ou incompletos, impossibilitando a integridade dos dados a 100%.

Ainda assim, procedeu-se à correção dos casos mais evidentes, nomeadamente quando o nome do torneio referia um país diferente do indicado na coluna "*Location*". Para além disto, ainda se realizou uma análise da maioria dos torneios comparativamente com a sua localização, tendo sido realizada uma pesquisa nos sites oficiais que permitiram perceber quando e onde se realizou um determinado torneio.

Um dos problemas com que nos deparámos foi com a existência de países que tiveram reestruturações e deram origem a novos países, como o caso da "*Yugoslavia*", pelo que optámos por manter esta designação nos casos em que não existem informações suficientes para determinar o país atual onde os torneios foram realizados. Contudo, quando o nome do torneio apresenta referências geográficas que associam este ex-território a um país, procedemos à atualização do país com base na localização atual dessas cidades. Por exemplo, os torneios que tinham "*Belgrade*" foram associados ao país "*Serbia*".

Relativamente aos jogos de Davis Cup e Fed Cup, optámos por uma abordagem conservadora. Embora estes eventos sejam normalmente associados ao país anfitrião, a ausência de contexto adicional dificultou a determinação precisa do país correto. Ao contrário do futebol, onde o primeiro clube mencionado indica tradicionalmente o anfitrião, o ténis não segue esta convenção de forma consistente.

Adicionalmente, observámos situações em que o nome do torneio mencionava dois países, mas a localização indicava um terceiro país diferente. Após verificação, constatámos que a localização estava correta, o que reforçou a decisão de não efetuar alterações sem informação confirmada, evitando introduzir erros adicionais nos dados.

4.5. Coluna "*Location"*

Relativamente à coluna "*Location"*, houve necessidade de se realizar uma padronização dos dados através da remoção das cidades presentes neste campo, visto que não contribuíam para as estatísticas pretendidas e apresentavam valores sem informação suficiente. Nos registos onde apenas constava a cidade, esta foi substituída pela informação correspondente do país.

Antes de procedermos à alteração dos campos da coluna "*Location*", a primeira operação executa através do comando UPDATE a verificação dos registos que contém vírgulas a separar "Cidade, País" ou "Cidade, Estado, País".

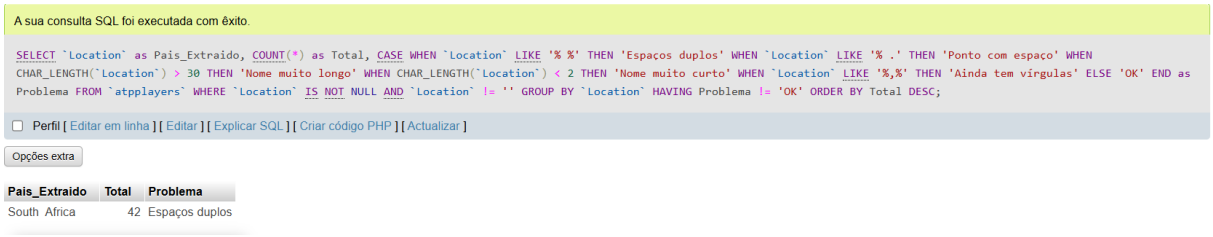
Caso o registo não contenha vírgulas, apenas remove os espaços em branco redundantes, podendo indicar que apenas contém a Cidade, o Estado ou o País. Caso contrário, extrai apenas o último segmento após a vírgula (que deveria de ser o país), removendo informação desnecessária.

Este procedimento permite uniformizar os registos de forma a apenas incluir informação sobre o "País". A operação é aplicada exclusivamente a registos não nulos e não vazios.

A segunda consulta produz um relatório estatístico que quantifica a frequência de cada localização na base de dados. Os resultados são ordenados por ordem decrescente de ocorrências e limitados aos 50 países mais representados, permitindo identificar a distribuição geográfica dominante no conjunto de dados.

Por fim, a terceira consulta implementa um sistema de validação que categoriza potenciais problemas de qualidade nos dados. São identificadas cinco categorias de anomalias: presença de espaços duplos consecutivos, formatação incorreta de pontuação, nomes excessivamente longos (superiores a 30 caracteres), nomes demasiado curtos (inferiores a 2 caracteres) e a presença residual de vírgulas. Apenas os registos problemáticos são apresentados no resultado, ordenados por frequência de ocorrência, facilitando a priorização de ações corretivas subsequentes.

Tendo apenas apresentado o problema de "Espaços Duplos" como apresentado na imagem.


A sua consulta SQL foi executada com êxito.

```
SELECT `Location` as Pais_Extraido, COUNT(*) as Total, CASE WHEN `Location` LIKE '% %' THEN 'Espaços duplos' WHEN `Location` LIKE '% .' THEN 'Ponto com espaço' WHEN
CHAR_LENGTH(`Location`) > 30 THEN 'Nome muito longo' WHEN CHAR_LENGTH(`Location`) < 2 THEN 'Nome muito curto' WHEN `Location` LIKE '%,%' THEN 'Ainda tem vírgulas' ELSE 'OK' END as
Problema FROM `atpplayers` WHERE `Location` IS NOT NULL AND `Location` != '' GROUP BY `Location` HAVING Problema != 'OK' ORDER BY Total DESC;
```

Perfil [Editar em linha] [Editar] [Explicar SQL] [Criar código PHP] [Actualizar]

Opções extra

Pais_Extraido	Total	Problema
South Africa	42	Espaços duplos

Não obstante Hong Kong, Aruba, Curaçao e Puerto Rico não serem países independentes, optou-se pela sua manutenção na lista, uma vez que estas localizações constam como entidades reconhecidas nas plataformas oficiais da ITF (International Tennis Federation) e da ATP (Association of Tennis Professionals), sendo tratadas como países ou localizações distintas no contexto desportivo internacional do ténis.

Durante a análise, identificámos um torneio cuja localização estava registada como *"Pacific Oceania"*. Dado o carácter ambíguo dessa designação, procedemos à verificação detalhada das informações do evento e concluímos que o torneio foi, na verdade, realizado em "*Guam*", incluído nos "*Federated States of Micronesia*". Esta correção foi essencial para garantir a precisão geográfica dos dados analisados.

Através das imagens, é possível perceber o problema identificado e como este foi solucionado com base numa notícia e na base de dados disponibilizada com as siglas dos países.

Tournament	Location
POC vs. THA AOGII 1st RD	Pacific Oceania



Thailand whitewash Pacific Oceania in tennis Davis Cup tie

11:05 am on 7 March 2011 Share this

There was no final fling for Pacific Oceania who dropped both reverse singles matches on Sunday to lose their Davis Cup tie with Thailand 5-0 in Guam.

Michael Leong offered some resistance in the opening set before falling 6-4 6-0 to former top 100 player Danai Udomchoke.

Cyril Jacobe was unable to match the power hitting of Kittapong Wachiramanowong, who won 6-2 6-2 to complete the rout.

The home team lost both opening singles rubbers on Friday before going down in the doubles on Saturday.

Para além dos países que necessitaram de ser alterado verificou-se registos em que não havia qualquer informação da "*Location*" a partir das abreviações "*TBA*", "*TBD*" e "*TBC*", que referem que os dados ainda estão por confirmar.

Location
Thailand
Tunisia
Turkey
TBA
Togo
Taiwan
TBD
TBC
Trinidad and Tobago
Tajikistan

Desta forma, teve de se comparar os valores do "*Tournament*" para perceber de que país se poderia tratar, visto que não haveria informação suficiente. Juntamente a esta análise e preenchimento da coluna "*Location*" tendo em conta o "*Tournament*" recorreu-se aos sites oficiais para permitir ter uma análise mais fiável.

4.6. Coluna "*Date*"

Através da análise dos dados da coluna "*Date*" podemos comprovar que não existem valores em branco. Apesar disto, houve a necessidade de criar duas colunas adicionais ("*StartDate*" e "*EndDate*") que substituem a coluna "*Date*" devido ao facto de termos dois tipos de informação (a data de início e a data de fim do torneio), pelo que é correto reduzir a complexidade dos dados para facilitar as suas estatísticas.

4.7. Coluna "*Ground"*

Durante o processo de limpeza dos dados, identificou-se a presença de strings vazias, explicando a ausência de informação em determinados registos.

Para tal, optou-se por preencher estes campos com valores NULL, permitindo garantir a consistência estatística do *dataset*, evitando que estes registos interfiram em operações como SUM e COUNT, que possam comprometer os valores reais das estatísticas.

4.8. Coluna "*Prize"*

Atendendo aos registos da coluna "*Prize*", tivemos de separar os valores da coluna "*Prize*" em outras duas colunas, uma que incluisse o valor do prémio ("*PrizeValue*") e outra com a *currency* que será entregue o prémio ("*PrizeCurrency*").

Como existem caracteres especiais que não estão definidos na coluna optou-se por deixar o registo na coluna "*PrizeCurrency*" com valor NULL.

Assim, alterou-se os símbolos de cada moeda para a designação da moeda, nomeadamente, "€" para "EUR", "$" para "USD", "A$" para "AUD" e "£" para "GBP".

4.9. Coluna "*WL"*

Nesta coluna apenas foi necessário preencher os valores em branco para NULL, de forma a permitir que estes não sejam contabilizados para fins de estatísticas.

4.10. Coluna "*Score"*

Primeiramente, analisando os valores da coluna "*Score*", temos de alterar os valores que estão a texto "null" para um valor especial NULL, pois se fizéssemos estatísticas com esse valor em texto, este não reconhecia que era um valor que não conta para as estatísticas.

Durante esta análise percebeu-se que existem vários valores registados para além do marcador dos jogos, nomeadamente, "(W/O)", "(RET)" e "(DEF)". Estes valores enquanto indicativos ajudam-nos a perceber o que aconteceu e como ficou cada jogo.

- **(W/O):** quer dizer que o jogador desistiu antes de começar o *match* pelo que o seu adversário ganha sempre que esta situação se verifique e por isso não existe um *score;*
- **(RET):** refere-se à desistência de um jogador durante o jogo, estando o marcador preenchido até sair do jogo;
- **(DEF):** destaca o jogador que foi o vencedor naquele jogo;

De forma a podermos organizar melhor os dados apresentados e a fazer a distinção entre *sets* e mais do que um jogo realizado apresentado no mesmo *score*, substituímos "," por ";" para destacar outros jogos que tenham sido realizados referentes ao mesmo *match*.

Por outro lado, com o intuito de destacar quantos *sets* ocorreram num *match* substituímos a separação através de espaços vazios por "-".

4.11. Coluna "*Round*"

Relativamente à coluna "*Round*", verificou-se que existiam inconsistências na distribuição das fases do torneio, tendo procedido a algumas alterações.

No que diz respeito ao registo "*Olympic Bronze*" alterou-se para "*3rd/4th Place Match*", pois ambos referem-se à disputa pelo 3ºlugar no torneio.

Ainda nas fases eliminatórias, para manter a consistência nestes dados alterou-se "*Quarter-Finals*", "*Semi-Finals*" e "*Quarter-Finals*" para, respetivamente, "*Round of 8*", "*Round of 4*" e "*Round of 2*".

4.12. Coluna "*OpponentRank*"

A única alteração que ocorreu nesta coluna foi o facto de haver valores apresentados por "-" e desta forma teve de se alterar para um valor especial "NULL" com o objetivos de não influenciar as estatísticas pretendidas.

4.13. Coluna "*Opponent*"

Através da consulta desta coluna foi notória a existência de strings vazias, indicando ausência de informação em determinados registos. De tal maneira, optou-se por substituir por valor especial NULL em todos os registos sem informação. Esta decisão tem por objetivo garantir a consistência estatística da base de dados, evitando que esses registos interfiram nas consultas necessárias.

5. Identificação de duplicados na base de dados

Durante a validação dos dados, foram identificadas 2830 linhas duplicadas na base de dados. Esta duplicação pode comprometer a integridade das análises estatísticas e gerar inconsistências nos resultados. A remoção ou tratamento adequado desses registos é essencial para garantir a fiabilidade dos dados e a precisão das métricas calculadas.



Desta forma, eliminou-se os duplicados de forma a não impactarem negativamente as estatísticas que serão utilizadas.

Esta remoção dos duplicados teve um impacto residual de 0,2% no *dataset*, tendo em conta o total das observações. Sendo uma parte ínfima de informação que foi eliminada, esta também não afeta a representatividade e a qualidade dos dados.

```
1 CREATE TABLE atpplayers_final
2 AS SELECT DISTINCT `PlayerName`, `Born`,`Height`, `Hand`, `Tournament`, `Location`, `Start_date`, `End_date`, `Ground`, `Prize`, `WL`,
  `Score`,`Round`,`Opponent`, `OpponentRank`
3 FROM atpplayers;
```

6. Estimação do Erro nas estatísticas

Tendo em conta, as várias modificações que o *dataset* necessitou é importante estimar o erro que nos permite comprovar que as estatísticas estão o mais próximas da realidade.

Tendo em conta os valores NULL que temos na base de dados podemos referir que temos um erro de, aproximadamente, 5% dos nossos dados, tendo em conta que este valor será necessário ter em conta na conclusão das estatísticas e nas decisões a tomar.

7. Estrutura do Banco de Dados

O banco de dados contém informação sobre os jogadores de ténis, jogos e torneios, bem como dados referentes a países e continentes.

Desta forma, apresentamos 5 tabelas com os dados fornecidos no *dataset*, bem como com informação adicional que permite ter uma análise mais robusta dos dados.

7.1. Tabela "*Continent*"

- Apresenta informação sobre como os países estão distribuídos por continentes;
- **Chave Primária:** "*nameContinent*";
- **Colunas incluídas:**
  - ***"nameContinent"*** – Nome do continente;
  - ***"SQMI"* e *"SQKM"* –** Área por milhas quadradas e km^2, respetivamente;
  - ***"Shape_Leng", "Shape_Area", "Shape__Area"* e *"Shape__Length"*** – apresenta informações geométricas detalhadas (adicional);
- Estas tabela permite realizar análises consoante o continente;

7.2. Tabela "*Country*"

- Apresenta os países que se relaciona tanto com a tabela "*Continent*", como "*Player*" e "*Tournament*";
- **Chave Primária:** "*code*"
- **Chave Estrangeira:** "*Continent*" → "*continent(nameContinent)*"
  - Sendo assim, se o valor da chave primária for atualizado, então quer dizer que o valor correspondente neste atributo é automaticamente atualizado (CASCADE);
  - Caso contrário, se uma linha for eliminada na chave primária, este comando impede que a mesma seja apagada na tabela relacionada (RESTRICT);
- **Colunas incluídas:**
  - ***"name"*** – Nome do país;
  - ***"Continent"* –** Respetivo continente de cada país;

7.3. Tabela "*Tournament*"

- Apresenta informações relativas aos torneios ATP, permitindo perceber relações com os jogos que serão realizados;

- **Chave Primária:** "*tournament_id*"
- **Chave Estrangeira:** "*country_code*" → "*country(code)*"
    - Sendo assim, se o valor da chave primária for atualizado, então quer dizer que o valor correspondente neste atributo é automaticamente atualizado (CASCADE);
    - Caso contrário, se uma linha for eliminada referente à chave primária, este comando obriga que o valor corresponde seja classificado como NULL (SET NULL);
- **Colunas incluídas:**
    - ***"tournament_name"*** – Nome do torneio;
    - ***"country_code"* –** refere-se ao código do país;
    - ***"start_date"* e *"end_date"*** – apresenta as datas em que o torneio se realiza;
    - ***"ground"*** – Tipo de superfície onde são realizados os torneios;

7.4. Tabela "*player*"

- Apresenta informações sobre os jogadores que participam nestes torneios;
- **Chave Primária:** "*player_id*"
- **Chave Estrangeira:** "*born_country_code*" → "*country(code)*"
    - Sendo assim, se o valor da chave primária for atualizado, então quer dizer que o valor correspondente neste atributo é automaticamente atualizado (CASCADE);
    - Caso contrário, se uma linha for eliminada referente à chave primária, este comando obriga que o valor corresponde seja classificado como NULL (SET NULL);
- **Colunas incluídas:**
    - ***"player_name"*** – Nome do jogador;
    - ***"born_country_code"* –** refere-se ao código do país onde o jogador é natural;
    - ***"born_city"*** – Cidade da qual o jogador provém;
    - ***"height"*** – apresenta a altura dos jogadores;
    - ***"hand_dominante"* e *"backhand_style"*** – inclui a mão dominante, bem como o estilo preferido de *backhand*

7.5. Tabela "*match_atp*"

- Apresenta informações relativas a cada jogo que ocorreu no torneio e em determinadas condições;
- **Chave Primária:** "*match_id*"
- **Chave Estrangeira:**
    - "*playername_id*" → "*player(player_id)*"
        - Sendo assim, se o valor da chave primária for atualizado, então quer dizer que o valor correspondente neste atributo é automaticamente atualizado (CASCADE);
        - Caso contrário, se uma linha for eliminada na chave primária, este comando impede que a mesma seja apagada na tabela relacionada (RESTRICT);
    - "*tournament_id*" → "*tournament(tournament_id)*"
        - Sendo assim, se o valor da chave primária for atualizado, então quer dizer que o valor correspondente neste atributo é automaticamente atualizado (CASCADE);
        - Caso contrário, se uma linha for eliminada na chave primária, este comando impede que a mesma seja apagada na tabela relacionada (RESTRICT);
- **Colunas incluídas:**
    - ***"score"*** – Marcador do jogo;
    - ***"round"* –** refere-se à fase do torneio em qual o jogo foi disputado;
    - ***"opponent"*** – Oponente do jogador a que se refere uma dada linha;
    - ***"wl"*** – representa a vitória ou derrota do jogador;
    - ***"opponentRank"*** – inclui o ranking em que se encontrava o oponente na altura em que se realizou o jogo;

Durante todo este processo de distribuir os dados por diferentes tabelas, com o objetivo final de se apresentar os dados segundo o modelo relacional e de forma a possibilitar diversas estatísticas, foi necessário criar as colunas "*playername_id",* "*tournament_id"* e "*born_country_code"*. Estas colunas funcionam como chaves primárias e estrangeiras, permitido relacionar os dados entre diferentes tabelas, facilitando a execução de queries e reduzindo redundâncias nos dados.

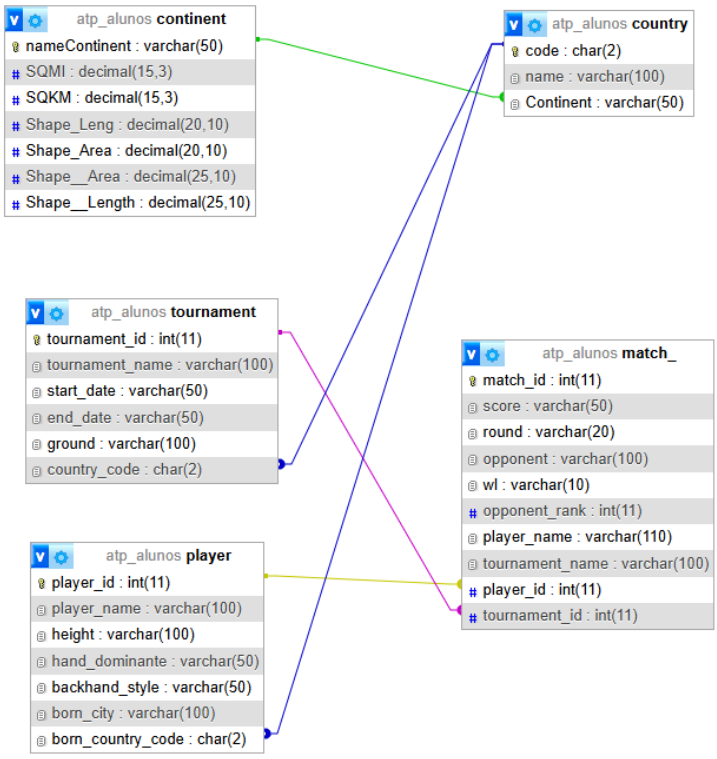
As colunas "*location"* (tabela "*tournament*") e "*born_country*" (tabela "*player*") retiraram-se devido ao facto de haver redundância e não ser necessário ter estes dados a repetirem-se, pois já temos criadas as chaves estrangeiras que solucionam este problema.

Por fim, após a criação do modelo relacional, criaram-se índices nas várias tabelas de forma a permitir a realização de queries rapidamente devido ao volume de dados que o *dataset* contém. Nas seguintes colunas (todas na tabela "match") criaram-se os seguintes índices através do comando INDEX:

- ***idx_player_name:*** permite procurar rapidamente o nome do jogador pretendido;
- ***idx_player_id*****:** com o objetivo de facilitar a consulta por *id* dos jogadores;
- ***idx_tournament_name*****:** permite facilitar a consulta por nome dos torneios;
- ***idx_tournament_id:*** facilita a consulta por *id* quando nos referimos aos torneios;

Ainda destaca-se que houve a necessidade de criar índices auxiliares de importação (***idx_atpplayers_playername***), ou seja, importou-se a coluna original "*PlayerName*" e "*Tournament*" e através destas criou-se um mapeamento para a tabela "*atpplayers*" que permitiu assim criar as colunas "*player_id*" e "*tournament_id*". Assim, permitiu tornar mais fácil a criação dos índices para estas mesmas colunas.

8. Modelo Relacional e Queries Solicitadas



Tendo em conta o modelo relacional apresentado e as queries que são solicitadas, podemos analisar um pouco melhor os nossos comandos.

Primeiramente, é nos solicitado que apresentemos uma consulta que incida no número de jogadores, no número de torneios e no número de jogos tendo em conta a análise destes registos por cada país que é apresentado na base de dados.

```
SELECT cy.name AS CountryName,
    COALESCE(P.TotalPlayers, 0) AS TotalPlayers,
    COALESCE(T.TotalTournaments, 0) AS TotalTournaments,
    COALESCE(M.TotalGames, 0) AS TotalGames
FROM country cy

-- 1. Subconsulta para contar Jogadores
LEFT JOIN (SELECT born_country_code, COUNT(player_id) AS TotalPlayers
FROM player
GROUP BY born_country_code) P ON cy.code = P.born_country_code

-- 2. Subconsulta para contar Torneios
LEFT JOIN (SELECT country_code, COUNT(tournament_id) AS TotalTournaments
FROM tournament
GROUP BY country_code) T ON cy.code = T.country_code

-- 3. Subconsulta para contar Jogos (Partidas)
LEFT JOIN (SELECT t.country_code, COUNT(m.match_id) AS TotalGames
FROM match_ m
JOIN tournament t ON m.tournament_id = t.tournament_id
GROUP BY t.country_code) M ON cy.code = M.country_code
ORDER BY cy.name;
```

CountryName	TotalPlayers	TotalTournaments	TotalGames
Afghanistan	0	0	0
Åland Islands	0	0	0
Albania	0	0	0
Algeria	19	35	1636
American Samoa	0	0	0
Andorra	0	13	693
Angola	0	0	0
Anguilla	0	0	0
Antarctica	0	0	0
Antigua and Barbuda	0	0	0
Argentina	447	436	24386
Armenia	14	7	396
Aruba	0	4	238
Australia	435	577	40835
Austria	3	357	20196
Azerbaijan	0	9	503
Bahamas	12	21	203
Bahrain	2	12	665
Bangladesh	1	2	115
Barbados	3	16	195
Belarus	33	68	2474
Belgium	100	229	11005
Belize	0	0	0
Benin	2	0	0
Bermuda	0	17	956

Assim, através da tabela podemos perceber que os principais jogadores os principais locais onde se realizam torneios e jogos são na Australia, devido ao facto de ser realizado o *"Australian Open*". Por outro lado, os jogadores onde se verificou mais jogadores foi na Argentina, mas logo a seguir vem novamente a Austrália.

Outra das análises que se pretende é listar os 10 melhores jogadores tendo de se apresentar os respetivos nomes e a percentagem de jogos vencidos, ordenada por ordem decrescente.

Desta forma, tivemos que aplicar o seguinte comando do MySQL:

```
SELECT p.player_name, (SUM(CASE WHEN m.wl = 'W' THEN 1.0 ELSE 0.0 END) * 100.0) /
COUNT(m.match_id) AS winning_percentage
FROM player p
```

```
JOIN match_ m ON p.player_id = m.player_id
GROUP BY p.player_name
HAVING COUNT(m.match_id) >= 10
ORDER BY `winning_percentage` DESC LIMIT 10
```

Após a introdução do comando é nos apresentada a seguinte tabela. Através da análise dos dados apresentados destacamos que o jogador Bjorn Borg teve uma percentagem de jogos ganhos de, aproximadamente, 80% ou seja, em média, em 100 jogos apenas perde 20 destes.

Apesar de se ter destacado dos restantes jogadores, não existe uma grande dispersão dos dados que nos fazem escolher evidentemente que o jogador Bjorn Borg é o melhor tenista desde 1973. Isto comprova-se devido ao facto de o jogador Carlos Alcaraz (último jogador na lista) ter apenas uma diferença de 6,1% do primeiro classificado.

player_name	winning_percentage ▼ 1
Bjorn Borg	79.975728
John McEnroe	77.845884
Ivan Lendl	77.110157
Jimmy Connors	76.936937
Roger Federer	75.888626
Novak Djokovic	75.859599
Rafael Nadal	75.283145
Juncheng Shang	75.000000
Brandon Wagner	74.285714
Carlos Alcaraz	73.913043

Por fim, podemos ainda comprovar que a tendência de jogadores que estão no top10 apresenta uma percentagem superior a 70% de vitórias, evidenciando os jogadores de elite que estão listados.

Ainda se pretende listar os 10 melhores jogadores canhotos apresentando os respetivos nomes e a percentagem de jogos ganhos em partidas de torneios "*Grand Slam"*.

Desta forma, tivemos que aplicar o seguinte comando do MySQL:

```
SELECT p.player_name, (SUM(CASE WHEN m.wl = 'W' THEN 1.0 ELSE 0.0 END) * 100.0) /
COUNT(m.match_id) AS gs_winning_percentage
FROM player p
JOIN match_ m ON p.player_id = m.player_id
```

```
JOIN tournament t ON m.tournament_id = t.tournament_id
WHERE p.hand_dominante = 'Left' -- FILTRO CORRIGIDO/CONFIRMADO: Usa 'Left' AND (
    t.tournament_name LIKE 'Australian Open%' OR
    t.tournament_name LIKE 'Roland Garros%' OR
    t.tournament_name LIKE 'Wimbledon%' OR
    t.tournament_name LIKE 'US Open%'
  )
GROUP BY p.player_name
HAVING COUNT(m.match_id) > 0
ORDER BY gs_winning_percentage DESC
LIMIT 10;
```

Após a introdução do comando é nos apresentada a seguinte tabela. Analisando, a percentagem de vitórias de jogadores canhotos em torneios "*Grand Slam*", podemos comprovar que neste caso já é possível destacar os melhores jogadores, tendo estes uma percentagem superior a 80%, respetivamente, Rafael Nadal (88%), Jimmy Connors (82%) e John McEnroe (81%). Apesar de se destacar neste caso Rafael Nadal com melhor desempenho nos torneios "*Grand Slam*".

Contrariamente, o top10 já apresenta uma maior dispersão devido ao facto de haver um maior afastamento do décimo classificado, sendo este, Denis Shapovalov com uma percentagem de vitórias de 65%.

player_name	gs_winning_percentage ▾ 1
Rafael Nadal	87.683284
Jimmy Connors	82.042254
John McEnroe	80.769231
Guillermo Vilas	75.675676
Alex Molcan	72.727273
Goran Ivanisevic	68.750000
Thomas Muster	67.241379
Andres Gomez	66.666667
Marcelo Rios	66.233766
Denis Shapovalov	64.705882

Por fim, é necessário apresentar os 5 melhores jogadores, incluindo os respetivos nomes e o número de jogos vencidos em piso "*Hard*" (ou seja, piso duro).

Desta forma, tivemos que aplicar o seguinte comando do MySQL:

```
SELECT p.player_name, COUNT(m.match_id) AS total_hard_ground_wins
FROM player p
JOIN match_ m ON p.player_id = m.player_id
JOIN tournament t ON m.tournament_id = t.tournament_id
WHERE m.wl = 'W' -- Filtra apenas vitórias AND t.ground = 'Hard'
-- Filtra por Hard Ground (Piso Duro)
GROUP BY p.player_name
ORDER BY total_hard_ground_wins DESC
LIMIT 5;
```

Após a introdução do comando é nos apresentada a seguinte tabela. Pelo que podemos analisar que o jogador Roger Federer destaca-se dos 5 melhores jogadores em piso "Hard" com uma diferença de 69 vitórias relativamente ao segundo classificado, Jimmy Connors.

Comparativamente com o último classificado, Harold Solomon, teve uma diferença de vitórias para o primeiro classificado de 187 vitórias.

Assim, podemos afirmar que em piso "Hard", o jogador Roger Federer apresenta-se como o melhor nestes torneios.

player_name	total_hard_ground_wins ▾ 1
Roger Federer	819
Jimmy Connors	750
Andre Agassi	679
Novak Djokovic	654
Harold Solomon	632

Assim, tendo em conta os dados apresentados, para tentar definir um possível melhor jogador de ténis com base no *dataset* apresentado podemos concluir que Rafael Nadal é um possível candidato, devido ao facto de ter um melhor desempenho nos "*Grand Slams*" apresentando-se como primeiro classificado nesse ranking, bem como de apresentar um peso expressivo quando analisamos o seu desempenho a nível geral dos jogos com uma percentagem de 75%, ou seja, encontra-se em sétimo lugar.

Outro fator que reforça este destaque é o facto de os torneios "*Grand Slams*" serem os principais torneios onde os tenistas mostram a sua qualidade e prestígio no ténis, reforçando a exigência, a duração do torneio e, evidentemente, o facto de ser um torneio mais prestigiado e competitivo.

Desta forma, Rafael Nadal apresentou-se estável nas estatísticas realizadas permitindo, assim, destacar o seu contributo e prestígio enquanto tenista profissional.

Bibliografia

https://www.rnz.co.nz/international/pacific-news/195752/thailand-whitewash-pacific-oceania-in-tennis-davis-cup-tie

List of all countries with their 2 digit codes (ISO 3166-1)

https://www.atptour.com/en/tournaments/braga/7913/overview

https://www.atptour.com/en/tournaments/lisbon/7742/overview

https://www.atptour.com/en/tournaments/oeiras/9514/overview

https://www.itftennis.com/en/tournament/espinho-challenger/por/1999/m-ch-por-01a-1999/draws-and-results/

https://www.atptour.com/en/tournaments/maia/8312/overview

https://www.atptour.com/en/tournaments/guimaraes/6793/overview

https://www.atptour.com/en/tournaments/azores/477/overview

https://www.itftennis.com/en/tournament/vilamoura-challenger/por/1989/m-ch-por-02a-1989/draws-and-results/